

自然语言处理作业一：基于不同文本表示的 NYT 新闻分类

刘迪乘

2312810

自然语言处理（2026 年秋季）

日期：2026 年 10 月 8 日

摘 要

本实验在 NYT 三类新闻分类（体育、政治、商业）上比较三类文本表示：词袋模型、静态词向量和预训练语言模型 BERT。所有方法共用同一个分层随机划分（训练、验证、测试为 80%/10%/10%），在 1152 篇测试文档上报告 Accuracy 与 Macro-F1。按作业要求的六个设置，测试集结果依次为：二元词袋 0.9896 / 0.9741，词频词袋 0.9913 / 0.9779；GloVe（100 维）0.9852 / 0.9646，在 AG News 上训练的 Word2Vec 0.9760 ± 0.0005 / 0.9415 ± 0.0016，只在 NYT 训练集上训练的 Word2Vec 0.9806 ± 0.0018 / 0.9524 ± 0.0037；bert-base-uncased 在最大长度 64、训练 3 个 epoch 后为 0.9826 ± 0.0009 / 0.9615 ± 0.0006（Word2Vec 与 BERT 为 3 个随机种子的均值 ± 标准差）。在作业设置下，词频词袋最好；BERT 只读入每篇新闻开头的 62 个子词，低于看到全文的词袋和 GloVe。额外实验中，将 BERT 的最大长度增加到 256 和 512 后，其均值超过词频词袋。逐类指标显示，各方法的错误主要集中在商业与政治两类之间。学习曲线和截断策略两组额外实验还显示，词袋在各训练规模下均不弱于 BERT（长度 64），而文档开头是 BERT 最有效的输入片段。

关键词：文本分类；词袋模型；Word2Vec；GloVe；BERT；Logistic Regression

1 实验目的

本实验在同一个文本分类任务上比较词袋模型、以 Word2Vec 与 GloVe 为代表的静态词向量，以及预训练语言模型 BERT。前两类表示配合 Logistic Regression 分类，BERT 按微调流程训练，最后统一用 Accuracy 与 Macro-F1 评价。具体目标为：

1. 理解不同文本表示的基本思想，完成文本分类的完整实验流程；
2. 掌握 Logistic Regression 在文本分类中的使用；
3. 掌握 Word2Vec、GloVe 等词向量的训练与使用；
4. 熟悉 BERT 类预训练语言模型的微调；
5. 比较各类表示的效果，并结合逐类指标与错误样例进行分析。

2 数据集与划分

NYT 数据集共 11519 篇新闻，每篇带有体育（sports）、政治（politics）、商业（business）三类标签之一。正文已经全部转为小写。按作业要求，先随机打乱，再按 80%/10%/10% 划分为训练集、验证集和测试集。划分时按标签分层，使三个子集的分类比例一致；随机种子固定为 42，所有实验共用这一划分。各子集的规模与类别分布见表 1。体育类约占 75%，政治类和商业类各约占 12.5%，类别明显不均衡，因此除 Accuracy 外，还需要对三类等权平均的 Macro-F1。

表 1: NYT 数据集的划分与类别分布 (篇)

子集	体育	政治	商业	合计
训练集	6911	1161	1143	9215
验证集	864	145	143	1152
测试集	864	145	143	1152
合计	8639	1451	1429	11519

新闻正文较长。按 NLTK 分词, 训练集和测试集每篇的词数中位数分别为 766 和 782。按 bert-base-uncased 的 WordPiece 分词 (计入 [CLS] 与 [SEP]), 中位数分别为 871 和 888.5。最大长度为 64 时, 测试集 1152 篇全部会被截断; 即使最大长度取 512, 测试集仍有 931 篇被截断 (表 8)。

训练 Word2Vec 用到的 AG News 语料共 90000 篇新闻 (标题加摘要) [21], 只使用正文, 不使用其标签。该语料同样已经全部为小写, 与 NYT 和 uncased 的 GloVe 词表一致。

3 方法

3.1 分类目标与 Logistic Regression

设文档 d 的表示为向量 $\mathbf{x}_d$ 。三类表示的区别只在 $\mathbf{x}_d$ 如何得到, 最后一步相同: 用线性层把表示映射为三个类别分数 (logit) z_1, z_2, z_3 , 再经 Softmax 得到概率,

$$z_j = \mathbf{w}_j^\top \mathbf{x}_d + b_j, \quad p_j = \frac{\exp(z_j)}{\sum_{k=1}^3 \exp(z_k)}, \quad (1)$$

预测类别为 $\arg \max_j p_j$ 。

对词袋和静态词向量, 分类器是多项 Logistic Regression。scikit-learn [14] 默认带 ℓ_2 正则项, 训练目标为交叉熵加正则项:

$$\min_{W, \mathbf{b}} \sum_{i=1}^n -\log p_{y_i}(\mathbf{x}_i) + \frac{1}{2C} \|W\|_F^2, \quad (2)$$

其中 y_i 为第 i 篇训练文档的真实类别, $W = [\mathbf{w}_1, \mathbf{w}_2, \mathbf{w}_3]$, C 为正则强度的倒数 (默认 $C = 1$)。求解器为 saga [4]。BERT 的分类头同样是式 (1) 的线性层, 损失为交叉熵, 正则由 AdamW 的权重衰减 [10] 提供。

3.2 词袋模型

词袋模型把文档表示为固定词表上的向量, 忽略词序, 只保留词是否出现以及出现多少次。按作业要求比较以下两种表示, 另外补充 TF-IDF 作为额外对照。记文档 d 中词 w 的出现次数为 $\text{tf}(d, w)$:

- **二元词袋 (Binary BoW)**: $x_{d,w} = \mathbb{I}[\text{tf}(d, w) > 0]$, 同一个词重复出现不改变对应分量;
- **词频 (Word Frequency)**: $x_{d,w} = \text{tf}(d, w)$, 文档越长, 各分量整体越大;
- **TF-IDF (额外)**: $x_{d,w} = \text{tf}(d, w) \cdot \text{idf}(w)$, 其中 $\text{idf}(w) = \log \frac{1+N}{1+\text{df}(w)} + 1$, N 为训练文档数, $\text{df}(w)$ 为包含 w 的训练文档数; 之后对每篇文档做 ℓ_2 归一化。

分词统一使用 NLTK [3] 的 `word_tokenize`, 标点和单字符词作为独立的词保留。词表与逆文档频率只在训练集上估计, 验证集和测试集只做变换, 词表大小为 127053。

3.3 静态词向量

静态词向量把每个词映射为一个固定的低维稠密向量，语义相近的词在向量空间中距离较近。记词 w 的词向量为 $\mathbf{e}_w \in \mathbb{R}^{100}$ 。文档 d 用与词袋相同的方式分词，保留词向量词表中存在的词 $w_1, \dots, w_m$ （重复出现的词按出现次数计入），文档向量取平均：

$$\mathbf{x}_d = \frac{1}{m} \sum_{i=1}^m \mathbf{e}_{w_i}. \quad (3)$$

词表外（OOV）的词不参与平均；若 $m = 0$ 则取零向量（本实验的测试集中没有出现这种情况）。分类器、划分和评价方式与词袋实验相同，结果差异只来自词向量的来源。

GloVe [15] 是基于全局共现统计的词向量。记 X_{ij} 为词 i 与词 j 在窗口内的共现次数，GloVe 用加权最小二乘让词向量内积加偏置项拟合共现次数的对数： $\mathbf{e}_i^\top \tilde{\mathbf{e}}_j + b_i + \tilde{b}_j \approx \log X_{ij}$ 。本实验直接使用公开的 glove.6B 100 维向量（在 Wikipedia 2014 与 Gigaword 5 上训练，词表 400000），不在 NYT 上更新。图 1 是 GloVe 论文中说明其动机的例子：单独的共现概率难以区分相关与无关的上下文词，共现概率的比值则可以。

Probability and Ratio	$k = \text{solid}$	$k = \text{gas}$	$k = \text{water}$	$k = \text{fashion}$
$P(k \text{ice})$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k \text{steam})$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k \text{ice})/P(k \text{steam})$	8.9	8.5×10^{-2}	1.36	0.96

图 1: GloVe 论文中的共现概率示例（60 亿词语料）。与 ice 相关的 solid 使比值远大于 1，与 steam 相关的 gas 使比值远小于 1，而 water、fashion 这类与两者都相关或都无关的词比值接近 1。GloVe 因此直接对共现统计建模。图片来源：Pennington et al., 2014 [15]，表 1

Word2Vec [11, 12] 采用 skip-gram 结构：给定中心词，预测窗口内的上下文词，并用负采样代替对整个词表的 Softmax 归一化。本实验用 gensim [16] 自行训练两个模型，超参数相同（表 2）：

- **AG News 模型**：在 90000 篇 AG News 正文上训练，词表大小 25376；
- **NYT 模型**：只在 NYT 训练集的 9215 篇正文上训练，词表大小 31657。验证集和测试集的正文不参与词向量训练，与 GloVe、AG News 模型处于同一条件。

作为消融，第 5.3 节还报告了用 NYT 全部正文（含验证集和测试集）训练的模型，以衡量这种转导式泄漏的影响。




图 2: Word2Vec 的两种结构：CBOW 用窗口内的上下文词预测中心词 $w(t)$ ，skip-gram 用中心词预测上下文词。本实验使用右侧的 skip-gram。图片来源：Mikolov et al., 2013 [12]，图 1

3.4 预训练语言模型 BERT

BERT [5] 是用掩码语言模型等任务预训练的双向 Transformer 编码器。文本先被切成 WordPiece 子词，每层自注意力同时读取左右两侧的上下文，因此同一个词在不同语境下的表示不同，这是它与静态词向量的根本区别。本实验使用 bert-base-uncased (12 层、12 个注意力头、隐藏维度 768、词表 30522)，通过 Hugging Face Transformers [20] 加载。图 3 展示了 BERT 先预训练、再在下游任务上微调的流程。




图 3: BERT 的预训练与微调流程。微调时除输出层外沿用预训练的结构和参数；本实验是单文本分类，只在 [CLS] 位置的输出 C 上接分类头。图片来源：Devlin et al., 2019 [5], 图 1

输入序列以 [CLS] 开头、以 [SEP] 结尾。按作业要求，最大长度为 64，超出部分从末尾截断；这 64 个位置包含两个特殊符号，因此每篇新闻实际只保留开头的 62 个子词。[CLS] 的最后一层隐状态经过 BERT 的 pooler (全连接层加 tanh)，再经 dropout 输入随机初始化的线性分类头，输出三个 logit。微调时分类头与全部预训练参数一起更新，训练 3 个 epoch。每个位置的输入向量由词元嵌入、句段嵌入和位置嵌入相加得到 (图 4)。




图 4: BERT 的输入表示：词元嵌入、句段嵌入与位置嵌入逐位相加。本实验的输入只有一段文本，句段嵌入均为 E_A ；bert-base-uncased 只有 512 个位置嵌入，这也是其输入长度的上限。图片来源：Devlin et al., 2019 [5], 图 2

每个 epoch 结束后在验证集上计算 Macro-F1。本实验同时报告两个测试结果：(1) 训练满 3 个 epoch 后的模型（作业要求的设置，下文记为“末轮”）；(2) 验证集 Macro-F1 最高的 epoch 对应的检查点（下文记为“验证集最优”）。

4 实验设置

主要超参数见表 2。词袋与词向量实验的 Logistic Regression 使用默认 $C = 1$ ，主结果不调参；第 5.2 节另外给出用验证集选择 C 的额外实验。

表 2: 各方法的主要超参数

方法	超参数	取值
Logistic Regression (词袋、词向量)	正则 / C / 求解器	ℓ_2 / 1.0 / saga, 最大迭代 10000
	随机种子	42
Word2Vec	结构 / 维度 / 窗口	skip-gram / 100 / 5
	最低词频 / 负样本数 / epoch	5 / 5 / 5
	随机种子	42、43、44 (单线程, PYTHONHASHSEED=0)
BERT	模型 / 最大长度 / epoch	bert-base-uncased / 64 / 3
	批大小 / 学习率 / 权重衰减	32 / 2×10^{-5} / 0.01
	优化器 / 学习率调度	AdamW / 前 10% 步线性预热, 之后线性衰减
	梯度裁剪 / 随机种子	1.0 / 42、43、44

随机性。数据划分的种子始终为 42。Logistic Regression 固定 `random_state`，同一输入下结果确定，因此词袋和 GloVe 只运行一次。Word2Vec 的训练结果依赖随机初始化和负采样，BERT 依赖分类头初始化、dropout 和数据顺序，因此这两类方法各用 3 个随机种子 (42、43、44) 重复实验，报告均值 $\pm$ 样本标准差 ($n-1$ 归一化)。BERT 用 `transformers.set_seed` 同时固定 Python、NumPy 与 PyTorch (含 CUDA) 的随机数；GPU 上的浮点运算仍可能带来极小的不确定性：用 `run_all.sh` 完整重跑一次，词袋、GloVe、Word2Vec 以及最大长度 32、64 的全部 BERT 运行 (含主结果表) 与本报告的结果逐位一致，而最大长度 128 及以上的部分 BERT 运行会有数篇测试文档的预测不同，相应均值的变化小于种子间的标准差。

实验环境。所有实验在一台配有 8 张 NVIDIA H800 (80 GB) 的服务器上完成，BERT 每次只使用一张 GPU (驱动 570.124.06, CUDA 12.8)，CPU 为 Intel Xeon Platinum 8468V。软件版本为 Python 3.12.13、PyTorch 2.11.0、Transformers 5.17.0、scikit-learn 1.9.1、gensim 4.4.0、NLTK 3.10.3、NumPy 2.5.3。运行时间方面，三种词袋的向量化与 Logistic Regression 拟合分别耗时 35.4、109.8、22.0 秒 (saga 分别迭代 323、1851、50 次，均已收敛)；BERT 在最大长度 64 下训练 3 个 epoch (含每轮验证) 约 48–56 秒，最大长度 512 约 210 秒。

5 实验结果

5.1 主结果

表 3 汇总了作业要求的六个设置在 NYT 测试集上的结果，额外实验单独标出。各项的最好结果加粗。

在作业要求的设置下，两项指标的排序一致：词频词袋 > 二元词袋 > GloVe > BERT (长度 64) > Word2Vec (NYT) > Word2Vec (AG News)。所有方法的 Accuracy 都在 0.97 以上，说明体育、政治、商业三类新闻在用词上差别明显；方法之间的差异主要体现在 Macro-F1，也就是两个少数类上。下面分别讨论。

表 3: NYT 测试集 (1152 篇) 主结果。Word2Vec 与 BERT 为 3 个随机种子的均值 $\pm$ 标准差

任务	方法	设置	Accuracy	Macro-F1
1: 词袋	二元词袋	LR, $C = 1$	0.9896	0.9741
	词频	LR, $C = 1$	0.9913	0.9779
2: 词向量	GloVe	6B, 100 维	0.9852	0.9646
	Word2Vec	AG News 训练	0.9760 ± 0.0005	0.9415 ± 0.0016
	Word2Vec	NYT 训练集训练	0.9806 ± 0.0018	0.9524 ± 0.0037
3: BERT	bert-base-uncased	长度 64, 末轮 (第 3 轮)	0.9826 ± 0.0009	0.9615 ± 0.0006
	bert-base-uncased	长度 64, 验证集最优	0.9826 ± 0.0009	0.9611 ± 0.0012
额外实验				
1	TF-IDF	LR, $C = 1$	0.9896	0.9751
2	Word2Vec	NYT 全部正文训练 (泄漏)	0.9818 ± 0.0017	0.9546 ± 0.0042
3	bert-base-uncased	长度 512, 末轮	0.9931 ± 0.0009	0.9838 ± 0.0018

5.2 词袋模型

两种必做的词袋表示都很强。词频的 Accuracy 比二元词袋高 0.17 个百分点 (测试集上相差 2 篇文章), Macro-F1 高 0.38 个百分点。保留出现次数能区分“顺带提到一次”和“反复出现”的类别词, 例如一篇偶尔提到 *market* 的体育报道, 与反复出现 *market*、*bank*、*percent* 的商业报道。从 Logistic Regression 的权重看, 二元词袋中商业类权重最大的词包括 *company*、*companies*、*market*、*bank*, 政治类包括 *state*、*washington*、*republican*、*obama*, 体育类包括 *players*、*league*、*game*、*team*, 都是直观的分类标志词。额外对照的 TF-IDF (0.9896 / 0.9751) 与二元词袋的 Accuracy 相同, 在默认 $C = 1$ 下没有超过词频。

词袋在本任务上的优势与已有文献一致。Joachims [8] 指出, 文本分类的特征维度很高但大多数特征都与类别相关, 文档向量稀疏, 而且多数文本分类问题线性可分, 因此线性模型很适合词袋特征。Wang 和 Manning [19] 发现, 在主题分类上, 基于词袋 (及二元组) 的简单线性模型是很难超越的基线; fastText [9] 也表明, 在 AG News 等新闻主题分类数据集上, 基于 n -gram 词袋的线性模型与当时的深度模型精度相当。NYT 的三类划分同样以主题为主, 类别几乎由用词决定, 词袋表现最好并不意外。

正则强度 (额外)。表 4 给出用验证集选择 $C \in \{0.01, 0.1, 1, 10, 100\}$ 的结果。二元词袋和词频在 $C \geq 0.1$ 时测试结果完全不变, 正则强度基本不影响它们。二元词袋的验证集 Macro-F1 在 $C = 0.01$ 时略高, 但对应的测试 Macro-F1 反而下降到 0.9681, 说明在每类只有约 144 篇的少数类验证样本上, 这样小的差异很难可靠地区分不同设置。TF-IDF 特征经过 ℓ_2 归一化, 数值尺度小, 需要较弱的正则: $C = 0.01$ 时模型把所有文档都判为体育类 (Macro-F1 0.2857), 验证集选出的 $C = 100$ 在测试集上达到 0.9922 / 0.9812, 是所有词袋设置中最高的。主结果仍按作业要求使用默认 $C = 1$ 。

表 4: 词袋 + LR 在不同 C 下的 Macro-F1 (验证集 / 测试集, 额外实验)

表示	$C = 0.01$	$C = 0.1$	$C = 1$	$C = 10$	$C = 100$
二元词袋	0.9596 / 0.9681	0.9573 / 0.9741	0.9579 / 0.9741	0.9579 / 0.9741	0.9579 / 0.9741
词频	0.9561 / 0.9756	0.9575 / 0.9779	0.9575 / 0.9779	0.9575 / 0.9779	0.9575 / 0.9779
TF-IDF	0.2857 / 0.2857	0.8770 / 0.9272	0.9569 / 0.9751	0.9636 / 0.9775	0.9674 / 0.9812

5.3 静态词向量

三种词向量中 GloVe 最好 (0.9852 / 0.9646)，在 NYT 训练集上训练的 Word2Vec 次之，AG News 上训练的 Word2Vec 最低。两个 Word2Vec 模型在 3 个种子之间的标准差为 0.05–0.18 个百分点 (Accuracy)，远小于它们与 GloVe 的差距，因此这一排序是稳定的。

表 5 给出各词向量在 NYT 测试集上的覆盖情况。词级 OOV 率指测试集所有词中不在词向量词表里的比例，类型级 OOV 率指测试集中不同词形不在词表里的比例。覆盖率与分类效果的排序一致：GloVe 的词表最大，只有 1.95% 的测试词找不到向量；AG News 模型的词表最小，且领域与 NYT 不完全相同 (AG News 是短摘要，NYT 是长篇报道)，5.76% 的测试词和 60.24% 的测试词形没有向量。未登录词无法为文档向量提供信息，覆盖率越低，可用的类别线索越少。此外，GloVe 在约 60 亿词的语料上估计共现统计，而两个 Word2Vec 模型的训练语料小几个数量级，向量质量也相应较差。

表 5: 词向量在 NYT 测试集上的覆盖情况 (Word2Vec 为种子 42 的模型)

词向量	词表大小	词级 OOV 率	类型级 OOV 率
GloVe 6B 100d	400000	1.95%	27.93%
Word2Vec (AG News)	25376	5.76%	60.24%
Word2Vec (NYT 训练集)	31657	2.46%	42.68%
Word2Vec (NYT 全部正文, 泄漏)	35447	1.86%	36.33%

NYT 词向量的泄漏消融。原始代码用 NYT 的全部正文训练 Word2Vec，其中包括验证集和测试集的文本。虽然没有用到标签，但测试文本参与了表示学习。本次修订改为只用训练集训练，并把全部正文训练的版本作为消融。3 个种子下，全部正文版本为 0.9818 ± 0.0017 / 0.9546 ± 0.0042 ，仅训练集版本为 0.9806 ± 0.0018 / 0.9524 ± 0.0037 ：泄漏使词表从 31657 扩大到 35447、测试集词级 OOV 率从 2.46% 降到 1.86%，但两项指标只高出约 0.1 和 0.2 个百分点，与种子间的波动处于同一量级。这种泄漏带来的影响很小；为与 GloVe、AG News 模型公平比较，主结果仍采用仅训练集的版本。(修订前报告的单次结果为 0.9800 / 0.9506，与上述区间一致。)

与最好的词频词袋相比，GloVe 的 Accuracy 低 0.61 个百分点 (7 篇文档)，Macro-F1 低 1.33 个百分点。词袋为每个词保留独立维度，类别标志词可以直接进入线性分类器；平均词向量先把词压缩到 100 维，再对整篇近 800 个词取平均，少数关键的类别词会被大量通用词稀释。在本数据集类别用词差别明显的情况下，保留每个词的独立特征更有利于线性分类。

已有文献对平均池化的局限进行了讨论。Iyyer 等 [7] 表明，对词向量做无序平均再接深层网络，在情感和问答分类上就能与依赖句法结构的模型相当；Shen 等 [17] 进一步发现，对主题分类而言词序信息的贡献很小，简单的平均或最大池化就能接近 CNN 和 LSTM，词序在情感分析中更重要。本任务是主题分类，因此丢失词序不是主要瓶颈，更关键的是均匀平均：每个词的权重只由出现次数决定，高频的通用词主导了文档向量。Arora 等 [1] 提出按词频对词向量加权并去除公共主成分，能改善平均词向量的效果。相比之下，词袋上的 Logistic Regression 为每个词学习独立的权重，相当于有监督地完成了这种加权。

领域差异也影响静态词向量。AG News 由新闻标题加一两句摘要组成，NYT 则是平均近 800 词的长篇报道，用词分布不同。Gururangan 等 [6] 对预训练语言模型的研究表明，表示学习语料与目标领域越接近，下游任务效果越好。本实验的静态词向量也呈现同样的规律：NYT 模型的训练文档数只有 AG News 的约十分之一，结果仍高于 AG News 模型，测试集 OOV 率也更低 (表 5)。

5.4 预训练语言模型 BERT

表 6 给出最大长度 64 时 3 个种子每个 epoch 的训练损失、验证集指标，以及末轮和验证集最优检查点的测试结果。训练损失在 3 个 epoch 内从约 0.26 降到约 0.02，而验证集 Macro-F1 在第 2 个 epoch 后

基本不再提高：种子 42 和 44 在第 2 个 epoch 最高，种子 43 在第 3 个 epoch 最高。两种选择方式的测试 Accuracy 完全相同，Macro-F1 的均值只相差 0.04 个百分点，说明在 3 个 epoch 内没有明显过拟合，按作业要求训练满 3 个 epoch 是合理的。

表 6: BERT（最大长度 64）各 epoch 的训练损失与验证集指标，以及测试集结果

种子	Epoch	训练损失	验证 Acc	验证 Macro-F1	测试 Acc / Macro-F1
42	1	0.2791	0.9688	0.9319	
	2	0.0507	0.9757	0.9480	0.9818 / 0.9600（验证集最优）
	3	0.0222	0.9705	0.9363	0.9818 / 0.9621（末轮）
43	1	0.2561	0.9731	0.9419	
	2	0.0509	0.9757	0.9471	
	3	0.0180	0.9757	0.9480	0.9835 / 0.9609（两者相同）
44	1	0.2605	0.9722	0.9403	
	2	0.0488	0.9731	0.9413	0.9826 / 0.9625（验证集最优）
	3	0.0180	0.9731	0.9411	0.9826 / 0.9615（末轮）

在作业设置下，BERT 的 Accuracy (0.9826 ± 0.0009) 低于词频词袋 0.87 个百分点（约 10 篇文档），也略低于 GloVe，但高于两个 Word2Vec 模型。原因在于输入长度：BERT 只看到每篇新闻开头的 62 个子词，而测试集文档的子词数中位数约为 889，词袋和词向量则使用全文。新闻的导语常常是场景描写或人物故事，类别线索可能要到后文才出现（见第 5.9 节）。即便如此，BERT 用不到全文 10% 的内容就超过了基于全文的 Word2Vec，说明上下文相关的预训练表示信息密度更高。

截断是 BERT 处理长文档的通行做法：自注意力的计算量和显存随序列长度二次增长，位置嵌入也只有 512 个，Longformer [2] 等长文档模型正是为突破这一限制而提出。Park 等 [13] 在多个长文档分类数据集上的比较发现，只保留前 512 个 token 的 BERT 基线往往不逊于 Longformer 等更复杂的模型，说明很多文档的关键信息集中在开头；但当关键信息出现在后文时，挑选后文片段的方法更有优势。第 5.8 节的截断策略实验在 NYT 上检验了这一点。

5.5 逐类指标与混淆矩阵

表 7 给出各必做方法的逐类 F1 和错误类型（Word2Vec 与 BERT 取种子 42，BERT 为末轮模型）。所有方法在体育类上的 F1 都在 0.99 以上，Macro-F1 的差距几乎完全来自政治和商业两类。对词袋和词向量方法，绝大多数错误发生在商业与政治之间：词频词袋 10 个错误中有 9 个属于这两类互相混淆，主要是政治类被判为商业类（7 篇）。涉及国会预算、监管、贸易的报道同时含有两类的典型用词，本身就处于两类边界上。BERT（长度 64）的错误分布不同：21 个错误中有 11 个涉及体育类，明显多于其他方法（1-6 个），这与截断导致导语之外的体育线索缺失相符。

两个少数类的 F1 也解释了 Accuracy 与 Macro-F1 之间的差距：词频词袋两者相差 1.34 个百分点，AG News 词向量相差约 3.5 个百分点。少数类各只有约 144 篇测试文档，一篇错误就会使其召回率变化约 0.7 个百分点，而对 Accuracy 的影响不到 0.1 个百分点。

5.6 额外实验：BERT 的最大长度

为验证截断的影响，在其他设置不变的情况下，把最大长度依次取为 32 到 512，每个长度用 3 个种子训练。结果见表 8 和图 5。

两项指标随最大长度大体单调上升，其中从 32 到 128 的提升最快：长度 32 时 Accuracy 只有 0.9664，

表 7: 测试集逐类 F1 与错误类型计数 (“商 → 政” 表示真实为商业、被预测为政治, 其余类推)

方法	F1 商业	F1 政治	F1 体育	商 → 政	政 → 商	商 → 体	政 → 体	体 → 商/政	错误数
二元词袋	0.9580	0.9655	0.9988	5	5	1	0	1 / 0	12
词频	0.9658	0.9684	0.9994	2	7	0	0	1 / 0	10
GloVe	0.9444	0.9517	0.9977	6	7	1	0	2 / 1	17
Word2Vec (AG)	0.9103	0.9161	0.9965	9	13	2	1	2 / 1	28
Word2Vec (NYT)	0.9193	0.9310	0.9971	10	9	2	1	2 / 0	24
BERT-64	0.9481	0.9444	0.9936	4	6	2	3	3 / 3	21

表 8: 不同最大长度下 BERT 的测试结果 (3 个种子的均值 $\pm$ 标准差, 额外实验)。“截断篇数” 为测试集中长度超过上限的文档数

最大长度	截断篇数	末轮 Acc	末轮 Macro-F1	验证集最优 Acc	验证集最优 Macro-F1
32	1152	0.9664 $\pm$ 0.0018	0.9323 $\pm$ 0.0035	0.9664 $\pm$ 0.0018	0.9323 $\pm$ 0.0035
64 (要求)	1152	0.9826 $\pm$ 0.0009	0.9615 $\pm$ 0.0006	0.9826 $\pm$ 0.0009	0.9611 $\pm$ 0.0012
96	1149	0.9855 $\pm$ 0.0013	0.9664 $\pm$ 0.0026	0.9855 $\pm$ 0.0013	0.9664 $\pm$ 0.0026
128	1143	0.9870 $\pm$ 0.0009	0.9693 $\pm$ 0.0020	0.9870 $\pm$ 0.0009	0.9693 $\pm$ 0.0020
192	1103	0.9881 $\pm$ 0.0018	0.9724 $\pm$ 0.0048	0.9881 $\pm$ 0.0018	0.9724 $\pm$ 0.0048
256	1083	0.9916 $\pm$ 0.0005	0.9790 $\pm$ 0.0012	0.9916 $\pm$ 0.0005	0.9790 $\pm$ 0.0012
384	1016	0.9905 $\pm$ 0.0017	0.9779 $\pm$ 0.0037	0.9899 $\pm$ 0.0010	0.9770 $\pm$ 0.0027
512	931	0.9931 $\pm$ 0.0009	0.9838 $\pm$ 0.0018	0.9931 $\pm$ 0.0009	0.9838 $\pm$ 0.0018




图 5: BERT 测试集指标随最大长度的变化 (误差棒为 3 个种子的标准差)。水平点线为词频词袋的结果

低于所有其他方法；从长度 96 起，两项指标均超过 GloVe。之后的增益逐渐变小，256 与 384 的差别在一个标准差以内。256 和 512 的均值超过词频词袋，512 的 Accuracy 高 0.18 个百分点，Macro-F1 高 0.59 个百分点；不过 256 与词频词袋的差距小于种子间的标准差。Accuracy 与 Macro-F1 的差距随长度从 3.41 个百分点（长度 32）缩小到 0.93 个百分点（长度 512），表明保留更多正文主要改善了少数类。24 次运行中，只有长度 64 的两个种子在第 2 个 epoch、长度 384 的一个种子在第 1 个 epoch 达到验证集最优，其余都在第 3 个 epoch 最优，反映出较长输入在 3 个 epoch 内仍未饱和。

5.7 额外实验：学习曲线

为比较各表示对标注数据量的依赖，从训练集中按类别分层抽取 10%、25%、50% 的文档（抽样种子 42，验证集和测试集不变），分别训练词频词袋、GloVe 和 BERT（长度 64，3 个 epoch，其余超参数不变）。BERT 用 3 个种子，词袋和 GloVe 是确定性的，各运行一次；注意每个比例只抽了一次子集，子集抽样本身带来的波动没有估计。结果见表 9 和图 6。

表 9：不同训练集规模下的测试结果（Accuracy / Macro-F1，额外实验）。BERT 为长度 64、末轮模型，3 个种子的均值 $\pm$ 标准差

比例	训练篇数	词频词袋	GloVe	BERT（长度 64）
10%	921	0.9731 / 0.9392	0.9748 / 0.9384	0.9644 ± 0.0117 / 0.9155 ± 0.0300
25%	2303	0.9818 / 0.9582	0.9792 / 0.9483	0.9760 ± 0.0022 / 0.9471 ± 0.0054
50%	4607	0.9887 / 0.9720	0.9844 / 0.9613	0.9795 ± 0.0020 / 0.9555 ± 0.0040
100%	9215	0.9913 / 0.9779	0.9852 / 0.9646	0.9826 ± 0.0009 / 0.9615 ± 0.0006




图 6：测试集 Macro-F1 随训练集规模的变化（额外实验，BERT 误差棒为 3 个种子的标准差）

三种方法都随训练数据增加而稳定提升，且在每个比例下词频词袋的 Macro-F1 都不低于另外两种方法。只有 921 篇训练文档时，GloVe 与词袋几乎相同（Accuracy 甚至高 0.17 个百分点）：预训练词向量把语义相近的词映射到相近位置，在标注数据少时能弥补词袋特征过于稀疏的问题。数据增加后，词袋的提升更大：从 10% 到 100%，词袋的 Macro-F1 提高 3.87 个百分点，GloVe 只提高 2.62 个百分点，词袋为每个词学习独立权重的优势在数据充裕时才得到充分发挥。BERT 在 10% 数据时方差很大（Macro-F1 标准差 0.0300，最差的种子只有 0.8820）：921 篇文档、批大小 32、3 个 epoch 只对应 87 个更新步，微调结果对随机初始化和数据顺序很敏感；数据达到 25% 后，种子间的波动明显减小。在所有规模下，长度 64 的 BERT 都低于看到全文的词袋，说明它与词袋的差距主要来自截断，而不是训练数据不足。

5.8 额外实验：BERT 的截断策略

主实验只保留文档开头 (head)。参照 Sun 等 [18] 的做法，再比较两种策略：只保留结尾 (tail)，以及同时保留开头和结尾 (head+tail)。head+tail 按 Sun 等在长度 512 时使用的比例 (开头 128、结尾 382 个子词) 分配，即开头约占正文预算的四分之一：长度 64 时为开头 16 + 结尾 46 个子词，长度 128 时为开头 32 + 结尾 94 个子词。其余设置不变，每种组合用 3 个种子，结果见表 10。

表 10: 不同截断策略下 BERT 的测试结果 (Accuracy / Macro-F1, 3 个种子的均值 $\pm$ 标准差, 额外实验)

长度	检查点	head (开头)	tail (结尾)	head+tail
64	末轮	0.9826 $\pm$ 0.0009 / 0.9615 $\pm$ 0.0006	0.9728 $\pm$ 0.0010 / 0.9430 $\pm$ 0.0019	0.9815 $\pm$ 0.0018 / 0.9565 $\pm$ 0.0056
	验证集最优	0.9826 $\pm$ 0.0009 / 0.9611 $\pm$ 0.0012	0.9702 $\pm$ 0.0051 / 0.9360 $\pm$ 0.0128	0.9838 $\pm$ 0.0005 / 0.9630 $\pm$ 0.0012
128	末轮	0.9870 $\pm$ 0.0009 / 0.9693 $\pm$ 0.0020	0.9835 $\pm$ 0.0015 / 0.9639 $\pm$ 0.0035	0.9881 $\pm$ 0.0010 / 0.9728 $\pm$ 0.0030
	验证集最优	0.9870 $\pm$ 0.0009 / 0.9693 $\pm$ 0.0020	0.9835 $\pm$ 0.0015 / 0.9639 $\pm$ 0.0035	0.9881 $\pm$ 0.0010 / 0.9734 $\pm$ 0.0020

两个长度下, 只保留结尾都是最差的: 长度 64 时末轮 Accuracy 比只保留开头低 0.98 个百分点, Macro-F1 低 1.85 个百分点; 长度 128 时差距缩小到 0.35 和 0.54 个百分点。新闻的开头通常交代事件的主体和背景, 类别信息最集中, 这与 Park 等 [13] 观察到的“关键信息常在开头”一致。head+tail 的表现与长度有关: 长度 64 时开头只剩 16 个子词, 末轮 Macro-F1 比 head 低 0.50 个百分点, 而按验证集选择检查点时又略高 0.19 个百分点, 两种策略在误差范围内难分高下; 长度 128 时开头有 32 个子词, head+tail 的两种检查点都优于 head (末轮 Accuracy 高 0.11、Macro-F1 高 0.35 个百分点, 约为一个标准差), 与 Sun 等的结论方向一致; 但长度 128 的运行不能逐位复现 (见第 4 节), 重跑一次后两者末轮 Accuracy 的先后关系发生反转, 因此这一优势只是弱证据。结尾能提供与开头互补的信息, 但前提是开头保留的部分足够长。

5.9 错误分析

比较词频词袋与 BERT (长度 64、种子 42、末轮) 在测试集上的预测: 词袋错 10 篇, BERT 错 21 篇, 两者同时出错 4 篇; 有 17 篇是 BERT 错而词袋对。逐篇查看这 17 篇, 主要有两类情况:

- **导语不含类别线索。**例如一篇体育类报道开头讲述一对夫妇从夏威夷度假回来、丈夫出现痴呆症状的经过, 前 62 个子词里没有任何体育词汇, BERT 判为政治; 直到后文才交代主人公曾在 *n.f.l.* 担任七个赛季的锋线球员, 并出现 *football*、*coach* 等词。又如一篇体育类专栏开头写瑞典的咖啡文化, BERT 判为商业, 直到后半篇才说明作者是在瑞典俱乐部效力的足球运动员, *team*、*coach*、*season* 等词也都出现在后半篇。
- **导语中的误导性线索。**一篇讲信用卡旅行福利的商业类文章, 开头用 *n.c.a.a.* 男篮锦标赛的竞猜作比喻, BERT 判为体育。

此外, 还有几篇商业类报道开头即是国会、预算或财政部的内容 (例如财政部就债务上限向国会发出警告), BERT 判为政治。这类文章处在两类的边界上, 词袋方法同样容易在商业和政治之间混淆 (表 7)。上述样例印证了第 5.4 节的分析: 长度 64 的主要损失来自截断, 而不是 BERT 表示能力不足。

6 结论

本实验在同一 NYT 划分上比较了词袋、静态词向量和 BERT 三类文本表示。在作业要求的设置下, 词频词袋取得最好的结果 (Accuracy 0.9913, Macro-F1 0.9779), GloVe 次之, BERT (最大长度 64) 和两个 Word2Vec 模型随后。这一结论依赖于本任务的两个特点: 三类新闻用词差别明显, 且文档长度远超 BERT 的输入上限。主要发现如下:

- **词袋保留独立词特征。**类别标志词在词袋中各占一维，可以被线性分类器直接利用；平均词向量会把这些信号稀释在近 800 个词中。保留出现次数的词频表示略好于二元表示。
- **词向量的质量与覆盖率决定效果。**GloVe 词表最大、测试集 OOV 率最低，结果最好；AG News 模型受领域差异和词表较小的影响，结果最差。NYT 词向量即使见过测试正文，提升也只有约 0.1 个百分点，与种子波动相当。
- **BERT 的瓶颈是输入长度。**在长度 64 下，BERT 只读到开头的 62 个子词，仍超过基于全文的 Word2Vec；随着最大长度增加，其结果持续提升，在 256 和 512 时超过词频词袋。错误样例表明，长度 64 时的多数额外错误来自导语缺少类别线索。
- **错误集中在商业与政治之间。**体育类几乎没有错误，Macro-F1 的差距主要由商业与政治两类之间的混淆决定。
- **额外实验。**学习曲线显示，只有 921 篇训练文档时 GloVe 与词袋相当，数据越多词袋的优势越明显，长度 64 的 BERT 在各规模下都低于词袋；截断策略实验表明，文档开头是最有效的输入片段，长度 128 时同时保留开头和结尾的 Macro-F1 高约 0.35 个百分点，但差距在噪声范围内。

不足与改进方向。(1) BERT 在长度 512 时仍有 931 篇测试文档被截断，长文档可尝试分段编码再聚合各段的 [CLS] 表示，或使用 Longformer [2] 等长文档模型；(2) 平均词向量可改为 TF-IDF 或 SIF [1] 加权平均，减弱常见词的稀释作用；(3) 可在损失函数中按类别加权，观察 Macro-F1 是否有所改善；(4) BERT 的学习率、批大小等只取了一组设置，较长输入在 3 个 epoch 内尚未饱和，后续可扩大参数搜索范围；(5) 测试集中少数类各只有约 144 篇，方法之间差异通常只涉及数篇文档，更稳健的比较需借助更多随机种子或交叉验证。

代码与复现

全部代码、结果文件与运行说明位于 GitHub 仓库 <https://github.com/July-h5kf3/nlp-NKU-2026>。hw1/code 中的 BoW.py、word2Vec.py、bert.py 分别对应三个任务，stats.py 统计数据集，summarize.py 汇总结果；每次运行的完整指标（含逐类 P/R/F1、混淆矩阵和测试集预测）保存在 hw1/results/ 下的 JSON 文件中，本报告中的所有数字均来自这些文件。在仓库根目录执行以下命令即可复现全部结果，环境配置与数据准备见仓库中的 README.md：

```
export PYTHONHASHSEED=0
uv run python hw1/code/BoW.py --method binary           # Task 1
uv run python hw1/code/BoW.py --method frequency
uv run python hw1/code/word2Vec.py --method glove       # Task 2
uv run python hw1/code/word2Vec.py --method ag --train --seed 42
uv run python hw1/code/word2Vec.py --method nyt --train --seed 42
uv run python hw1/code/bert.py --max_length 64 --seed 42 # Task 3
uv run python hw1/code/bert.py --max_length 128 --truncation head_tail # extra
uv run python hw1/code/BoW.py --method frequency --train_fraction 0.1 # extra
./run_all.sh --required # main table only; drop --required to run all extras
```

参考文献

- [1] Sanjeev Arora, Yingyu Liang, and Tengyu Ma. “A Simple but Tough-to-Beat Baseline for Sentence Embeddings”. In: *International Conference on Learning Representations*. 2017.
- [2] Iz Beltagy, Matthew E. Peters, and Arman Cohan. “Longformer: The Long-Document Transformer”. In: *arXiv preprint arXiv:2004.05150* (2020).
- [3] Steven Bird, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O’Reilly Media, 2009.

- [4] Aaron Defazio, Francis Bach, and Simon Lacoste-Julien. “SAGA: A Fast Incremental Gradient Method with Support for Non-Strongly Convex Composite Objectives”. In: *Advances in Neural Information Processing Systems*. Vol. 27. 2014.
- [5] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*. 2019, pp. 4171–4186.
- [6] Suchin Gururangan et al. “Don’t Stop Pretraining: Adapt Language Models to Domains and Tasks”. In: *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. 2020, pp. 8342–8360.
- [7] Mohit Iyyer et al. “Deep Unordered Composition Rivals Syntactic Methods for Text Classification”. In: *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing*. 2015, pp. 1681–1691.
- [8] Thorsten Joachims. “Text Categorization with Support Vector Machines: Learning with Many Relevant Features”. In: *Proceedings of the 10th European Conference on Machine Learning*. Vol. 1398. Lecture Notes in Computer Science. 1998, pp. 137–142.
- [9] Armand Joulin et al. “Bag of Tricks for Efficient Text Classification”. In: *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics (Volume 2: Short Papers)*. 2017, pp. 427–431.
- [10] Ilya Loshchilov and Frank Hutter. “Decoupled Weight Decay Regularization”. In: *International Conference on Learning Representations*. 2019.
- [11] Tomas Mikolov et al. “Distributed Representations of Words and Phrases and their Compositionality”. In: *Advances in Neural Information Processing Systems*. Vol. 26. 2013.
- [12] Tomas Mikolov et al. “Efficient Estimation of Word Representations in Vector Space”. In: *Workshop Proceedings of the International Conference on Learning Representations*. 2013.
- [13] Hyunji Hayley Park, Yogarshi Vyas, and Kashif Shah. “Efficient Classification of Long Documents Using Transformers”. In: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. 2022, pp. 702–709.
- [14] Fabian Pedregosa et al. “Scikit-learn: Machine Learning in Python”. In: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.
- [15] Jeffrey Pennington, Richard Socher, and Christopher D. Manning. “GloVe: Global Vectors for Word Representation”. In: *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*. 2014, pp. 1532–1543.
- [16] Radim Řehůřek and Petr Sojka. “Software Framework for Topic Modelling with Large Corpora”. In: *Proceedings of the LREC 2010 Workshop on New Challenges for NLP Frameworks*. 2010, pp. 45–50.
- [17] Dinghan Shen et al. “Baseline Needs More Love: On Simple Word-Embedding-Based Models and Associated Pooling Mechanisms”. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics*. 2018, pp. 440–450.
- [18] Chi Sun et al. “How to Fine-Tune BERT for Text Classification?” In: *Chinese Computational Linguistics (CCL 2019)*. Vol. 11856. Lecture Notes in Computer Science. 2019, pp. 194–206.
- [19] Sida Wang and Christopher D. Manning. “Baselines and Bigrams: Simple, Good Sentiment and Topic Classification”. In: *Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. 2012, pp. 90–94.
- [20] Thomas Wolf et al. “Transformers: State-of-the-Art Natural Language Processing”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. 2020, pp. 38–45.
- [21] Xiang Zhang, Junbo Zhao, and Yann LeCun. “Character-level Convolutional Networks for Text Classification”. In: *Advances in Neural Information Processing Systems*. Vol. 28. 2015.